MODELO PREDICTIVO BASADO EN INTELIGENCIA ARTIFICIAL PARA LA DETECCIÓN TEMPRANA DEL RIESGO DE EUTROFIZACIÓN

Análisis del Riesgo Ambiental en Cuencas Agrícolas Mediante Aprendizaje Automático y Sistemas de Alerta Temprana

Proyecto de Investigación

Instituto Tecnológico de Culiacán

Carrera: Ingeniería en Sistemas Computacionales

Materia: Tópicos de Inteligencia Artificial

Docente: Mora Felix Zuriel Dathan

Integrantes del Equipo:

Archuleta Izabal Luis Enrique

Ramírez Ruiz Santiago

ÍNDICE

Introducción 4

Objetivo general 5

Objetivos específicos 5

Justificación 6

Alcance 7

Desarrollo 9

1. El fenómeno de la eutrofización y sus etapas 9

1.1 ¿Qué es la eutrofización? 9

1.2 Origen natural y antropogénica. 9

1.3 Etapas de la eutrofización 9

1.4 Soluciones actuales 10

1.4.1 Soluciones basadas en la naturaleza 10

1.4.2 Tratamiento biológico 11

1.4.3 Soluciones mecánicas y de ingeniería 11

1.4.4 Control directo en la fuente (Tratamiento de descargas) 11

2. Contexto agrícola y ambiental de Sinaloa 12

2.1 Actividad agrícola y uso de fertilizantes en los distritos de riego (Culiacán y Sinaloa) 12

2.2 Antecedentes de eutrofizacion documentados en cuerpos de agua en la region. 12

3. Fundamentos de la solución basada en Inteligencia Artificial 13

3.1 ¿Por qué IA y no solo estadística tradicional? 13

3.2 Machine Learning aplicado a monitoreo ambiental: antecedentes 14

3.3 Algoritmos seleccionados: árboles de decisión y métodos de ensamble 14

4. Metodología 16

4.1 Fuentes y recolección de datos 16

4.1.1 Periodo de estudio 16

4.1.2 Sitios de monitoreo elegidos en Sinaloa 16

4.2 Variables del modelo 16

4.2.1 Parámetros fisicoquímicos básicos: 16
4.2.2 Nutrientes y materia orgánica: 17
4.2.3 Variables objetivo : 17
4.2.4 Variable contextual: 17
4.3 Preprocesamiento de datos 17
4.4 Definición de las clases de riesgo 18
4.5 Entrenamiento y validación del modelo 19
Agenda 20
Conclusiones 22
Citas Bibliográficas 23

Introducción

Sinaloa es conocido en todo el país como el líder en producción de alimentos gracias a sus extensos campos de cultivo. Sin embargo, para lograr estas grandes cosechas se utilizan a diario grandes cantidades de fertilizantes. Cuando los campos se riegan o cuando llueve fuerte, una parte de estos químicos no es absorbida por las plantas y termina siendo arrastrada hacia los drenes agrícolas y los ríos principales del estado (como el río Culiacán o el río Sinaloa).

El gran problema es que estos fertilizantes contienen nutrientes que sirven de alimento desmedido para algas y plantas acuáticas en los ríos. Al crecer de golpe y de forma descontrolada, forman una capa que bloquea la luz del sol. Peor aún: cuando estas plantas mueren y se pudren en el fondo, consumen casi todo el oxígeno disuelto en el agua. Este fenómeno se conoce como eutrofización y crea zonas donde los peces, camarones y demás fauna acuática literalmente no pueden respirar y mueren de forma masiva.

Actualmente, las revisiones del agua se hacen de forma manual: alguien va en lancha, toma una muestra y la manda a un laboratorio. El problema de este método es que los resultados tardan días o semanas; para cuando se descubre que el agua estaba en niveles peligrosos, la mortandad de peces ya ocurrió y el daño está hecho.

Aquí es donde entra la Inteligencia Artificial. En lugar de esperar a que el agua colapse, podemos entrenar un modelo computacional para que analice mediciones sencillas que ya se tienen registradas (como la temperatura del agua, el nivel de acidez o pH, los niveles de nutrientes y las fechas de riego). Con estos datos, la computadora aprende a identificar patrones y puede alertarnos con anticipación cuándo un río está a punto de quedarse sin oxígeno, permitiendo tomar medidas a tiempo para proteger la fauna y los ecosistemas de la región.

Objetivo general

Desarrollar un modelo predictivo de inteligencia artificial que analice parámetros fisicoquímicos y niveles de nutrientes (nitrógeno y fósforo) en el agua, con el fin de anticipar el riesgo de eutrofización y falta crítica de oxígeno (hipoxia) en los ríos y drenes agrícolas de Sinaloa para proteger la fauna acuática regional.

Objetivos específicos

1. **Compilar y estructurar la base de datos histórica:** Recopilar los registros oficiales de monitoreo de calidad del agua en las cuencas de Sinaloa, consolidando parámetros fisicoquímicos clave (temperatura, pH, conductividad eléctrica) y concentraciones de nutrientes (nitratos, fósforo total, demanda bioquímica de oxígeno y oxígeno disuelto).
2. **Preprocesar y normalizar los datos ambientales:** Aplicar técnicas de limpieza de datos para tratar valores atípicos y registros faltantes, organizando las observaciones en función de los ciclos agrícolas locales (temporadas de siembra, riego intensivo y estiaje).
3. **Entrenar y optimizar modelos de aprendizaje automático:** Implementar algoritmos de *Machine Learning* (como árboles de decisión y ensambles) capaces de modelar las relaciones no lineales entre la acumulación de nutrientes y el descenso crítico del oxígeno disuelto en el agua.
4. **Validar la precisión predictiva del sistema:** Evaluar el desempeño del modelo mediante métricas estandarizadas de error y clasificación (como precisión, sensibilidad, F1-score o RMSE, según el enfoque), comprobando su capacidad para clasificar correctamente el nivel de riesgo de eutrofización e hipoxia a partir de las condiciones fisicoquímicas registradas, como base para una alerta temprana ante posibles eventos de estrés hídrico.
5. **Diseñar una interfaz de visualización y alerta temprana:** Desarrollar un prototipo funcional de panel de control que clasifique los tramos de ríos y drenes en niveles de riesgo (bajo, moderado y crítico), como demostración del potencial de aplicación del modelo para apoyar la toma de decisiones preventivas por parte de autoridades y usuarios del agua.

Justificación

Como se planteó en la introducción, la agricultura intensiva de Sinaloa, sustentada en fertilizantes nitrogenados y fosfatados, genera un flujo constante de nutrientes hacia los drenes agrícolas y de ahí hacia ríos principales como el Culiacán y el Sinaloa. Este fenómeno de eutrofización e hipoxia no es un riesgo hipotético: evaluaciones de calidad del agua superficial en la región muestran que una proporción considerable de los sitios monitoreados en cuencas de Sinaloa presenta niveles de contaminación clasificados en semáforo amarillo o rojo, lo que confirma que el deterioro ya está ocurriendo de forma medible.

El principal obstáculo para atender este problema a tiempo es el método de monitoreo actual: como se mencionó, la toma de muestras se realiza de forma manual (en lancha) y su análisis en laboratorio puede tardar días o semanas. Para cuando los resultados confirman niveles peligrosos de nutrientes o bajo oxígeno disuelto, la mortandad de fauna acuática ya ocurrió y el daño ecológico es, en muchos casos, irreversible. Este desfase entre la toma de la muestra y la disponibilidad del resultado es precisamente la ventana de tiempo que un modelo predictivo de inteligencia artificial puede cerrar.

Al entrenar un modelo con datos históricos de parámetros fisicoquímicos (temperatura, pH, conductividad, nitratos, fosfatos, demanda bioquímica de oxígeno y oxígeno disuelto) junto con información del ciclo agrícola (temporadas de riego, siembra y estiaje), es posible identificar los patrones que anteceden a un evento crítico de hipoxia, sin depender de que un análisis de laboratorio confirme el daño después de ocurrido. Esto permite pasar de un esquema reactivo donde se actúa tras el colapso ambiental a uno preventivo, donde autoridades y usuarios del agua reciben una alerta con margen de tiempo suficiente para intervenir.

Este proyecto se justifica, entonces, en la necesidad de una herramienta accesible y de bajo costo que complemente el monitoreo tradicional, aprovechando datos que ya se recopilan de forma rutinaria, para proteger la fauna acuática y contribuir a un manejo más sustentable del agua en una de las regiones agrícolas más importantes de México.

Alcance

El presente proyecto se enfoca en el análisis de la calidad del agua de los ríos y drenes agrícolas asociados a las cuencas de los ríos Culiacán, Sinaloa, El Fuerte y Presidio, por ser los cuerpos de agua más relevantes para la actividad agrícola del estado y los que presentan mayor disponibilidad de registros históricos de monitoreo. No se pretende abarcar la totalidad de las cuencas hidrológicas de Sinaloa, sino trabajar con una muestra representativa de estaciones de monitoreo estratégicas dentro de estas cuatro regiones, abarcando desde zonas altas/medias hasta zonas de descarga costera y confluencia con drenes agrícolas, incluyendo los Distritos de Riego 010 (Culiacán-Humaya), 063 (Guasave) y 075 (Valle del Fuerte).

Para el desarrollo del modelo se utilizarán datos históricos secundarios, obtenidos principalmente de la Red Nacional de Medición de Calidad del Agua (RENAMECA) de CONAGUA, correspondientes aproximadamente a los últimos 8-10 años disponibles públicamente, con muestreos periódicos (mensuales/bimestrales) que permiten contrastar la época de sequía con la temporada de lluvias. El proyecto no contempla la instalación de sensores propios ni la toma de muestras en campo, dado el periodo de siete meses con el que se cuenta para su desarrollo; se trabaja exclusivamente con información ya recopilada por organismos oficiales.

Las variables consideradas dentro del análisis serán los parámetros fisicoquímicos e indicadores de nutrientes disponibles en dichas fuentes (temperatura, pH, conductividad eléctrica, nitratos, nitritos, nitrógeno amoniacal y fósforo total), así como la temporalidad del ciclo agrícola (periodo de riego intensivo/aplicación de fertilizantes frente a periodo de receso) como variable contextual. El oxígeno disuelto (OD) y la demanda bioquímica de oxígeno (DBO5) se emplean como variables objetivo del modelo, es decir, los valores que el sistema busca predecir a partir de las demás variables.

En cuanto al producto final, el proyecto entregará:

Un modelo de aprendizaje automático (basado en árboles de decisión y/o ensambles) capaz de predecir el oxígeno disuelto y la demanda bioquímica de oxígeno, y de clasificar el nivel de riesgo de eutrofización e hipoxia (bajo, moderado, crítico) a partir de las condiciones fisicoquímicas registradas.

Un prototipo funcional de panel de visualización que muestre esta clasificación de forma accesible, entendido como una demostración del potencial de aplicación de la herramienta, y no como un sistema de monitoreo en tiempo real listo para producción.

Quedan fuera del alcance de este proyecto: la validación en campo con datos propios, la integración con sensores IoT en tiempo real, el despliegue del sistema como una

plataforma pública operativa, y el análisis de otros contaminantes no relacionados con nutrientes y oxígeno disuelto (como metales pesados o coliformes fecales), aun cuando también afectan la calidad del agua en la región.

Desarrollo

1. El fenómeno de la eutrofización y sus etapas

1.1 ¿Qué es la eutrofización?

La eutrofización se define como el enriquecimiento excesivo de nutrientes en un ecosistema acuático. Aunque comúnmente se asume que una mayor disponibilidad de alimento estimula el crecimiento biológico, el exceso de compuestos como nitrógeno, fósforo, silicio y carbono desestabiliza las dinámicas fisicoquímicas del agua. Esto rompe el equilibrio entre la producción primaria y la capacidad del sistema para asimilar materia orgánica. **(Castañeda-Ruelas et al., 2023)**

El concepto se utilizó por primera vez a inicios del siglo XX por los investigadores europeos Augusto Thienemann (1918) y Einar Naumann (1919) para describir los cuerpos que se encontraban en lagos en los cuales abundaba el fitoplancton a diferencia de otras acumulaciones de agua donde escaseaban los nutrientes.

1.2 Origen natural y antropogénica.

Aunque existen diferentes causas naturales por las cuales se puede acumular fósforo y nitrógeno a los cuerpos hídricos, el ritmo de estos procesos geológicos es sumamente lento en comparación con la influencia humana.

A partir de los siglos XIX y XX, la intensificación de las actividades antropogénicas (crecimiento urbano, expansión agropecuaria, uso masivo de fertilizantes, vertimiento de desechos domésticos e industriales sin tratar) superó drásticamente las tasas naturales de aporte de nutrientes. Este fenómeno provocado por el ser humano se le conoce como eutrofización cultural o antropogénica. Esta rompe el balance fundamental entre la generación y degradación de nutrientes orgánicos y asimilación controlada por parte de los productores primarios.

1.3 Etapas de la eutrofización

Enriquecimiento y proliferación de productores primarios: El ingreso excesivo de nutrientes (fósforo, nitratos y amonio) y materia orgánica estimula el crecimiento acelerado e incontrolado de biomasa fotosintética, principalmente fitoplancton, microalgas, macroalgas y plantas acuáticas vasculares invasoras (como el lirio acuático).

Aumento del consumo de oxígeno: Al incrementarse la densidad orgánica vegetal, se reducen los rayos solares (aumento de la turbidez). Con ello, la respiración de las bacterias y organismos se intensifica, demandando una mayor cantidad de oxígeno, para descomponer los excedentes orgánicos lo que desencadena una caída del oxígeno y un cambio en los valores de pH.

Colapso de oxígeno (Hipoxia y Anoxia): La continua descomposición agota por completo el oxígeno disuelto en el agua, generándose las denominadas zonas muertas o zonas hipóxicas/anóxicas. Esto provoca muertes masivas de fauna acuática (peces, moluscos y crustáceos) que no toleran tales déficits.



Figura 1. *Etapas del proceso de eutrofización cultural e hipoxia. Representa la secuencia desde el ingreso excesivo de nutrientes agrícolas hasta el colapso del oxígeno disuelto y la muerte de fauna acuática.*

1.4 Soluciones actuales

1.4.1 Soluciones basadas en la naturaleza

Consiste en utilizar plantas para limpiar el agua de forma ecológica y económica, inspirándose en sistemas naturales y ancestrales:

Islas flotantes de plantas (biofiltros): Se colocan estructuras o balsas flotantes con plantas acuáticas cuyas raíces quedan sumergidas en el agua. Estas plantas absorben directamente el exceso de nitrógeno y fósforo para alimentarse, quitándoles la comida a las algas dañinas. Además, ofrecen refugio y zonas de reproducción para peces y pequeños animales. (Macchiavelli, 2018, citado en Ticona Neyra et al., 2023, pp. 18-19; Ramírez-Zierold et al., 2023, pp. 28-29)

Uso controlado de plantas como el lirio acuático: Aunque fuera de control puede ser una plaga, si se mantiene delimitado en corrales flotantes, el lirio acuático es sumamente eficiente para atrapar nutrientes y bacterias. Una vez que crece, se puede retirar del agua para fabricar composta o abono natural para el campo. (Ramírez-Zierold et al., 2023, pp. 28-29).

Humedales artificiales y barreras vegetales: Se construyen canales o lagunas artificiales con piedras y plantas de la región que filtran el agua de los ríos y drenes antes de que sigan avanzando, o se siembran árboles y plantas a las orillas de los cauces para retener los fertilizantes que arrastran las lluvias. (Mateos-Aparici Baixauli, 2020, pp. 2-5)

1.4.2 Tratamiento biológico

Consiste en apoyarse en microorganismos benéficos para acelerar la limpieza del agua:

Bacterias naturales benéficas: Se introducen mezclas de bacterias seguras (no modificadas) que se alimentan de la materia orgánica acumulada en el fondo.

Competencia contra las algas: Estos microorganismos consumen de forma rápida los compuestos dañinos (como amonio, nitritos y fosfatos), dejando a las algas sin alimento y provocando que desaparezcan de forma natural.

1.4.3 Soluciones mecánicas y de ingeniería

Inyección de microburbujas de aire: A través de mangueras especiales colocadas en el fondo de lagunas o balsas, se inyecta aire constante. Esto devuelve el oxígeno que las bacterias necesitan para descomponer los desechos sin producir malos olores, y rompe el agua estancada para que no proliferen plagas ni algas.

Obras para mejorar la circulación: En lagunas costeras, esteros o bahías donde el agua no corre, se diseñan compuertas, esclusas o canales de conexión con el mar abierto. Esto permite que la marea y las corrientes marinas limpien y renueven el agua estancada de manera periódica.

Limpieza física y retiro de sedimentos: Extracción manual o con maquinaria del exceso de plantas invasoras en la superficie y retiro del lodo podrido acumulado en el fondo.

1.4.4 Control directo en la fuente (Tratamiento de descargas)

La medida más importante y preventiva consiste en evitar que el problema llegue al agua:

Plantas de tratamiento de aguas residuales: Tratar las aguas negras de ciudades, granjas e industrias antes de arrojarlas a los ríos.

Retiro y desvío de efluentes: Retirar las tuberías y drenajes clandestinos que arrojan aguas sucias directamente al agua. Los estudios demuestran que las obras en los ríos o lagunas no funcionan por sí solas si no se elimina al menos el 80% de las descargas contaminantes que entran a ellos. **(Zamora, 2010)**.

2. Contexto agrícola y ambiental de Sinaloa

2.1 Actividad agrícola y uso de fertilizantes en los distritos de riego (Culiacán y Sinaloa)

Sinaloa es la entidad con mayor extensión de agricultura de riego tecnificado en México: su infraestructura hidráulica está compuesta por 12 presas de gran envergadura, 8 Distritos de Riego y 49 Módulos de Riego, que en conjunto abarcan 752,218 hectáreas irrigadas (Mancera González, 2023). De estos distritos, el más relevante para este proyecto es el Distrito de Riego 010 Culiacán-Humaya, con 212,141 hectáreas, el segundo más extenso del estado después del Distrito de Riego 075 Río Fuerte (Mancera González, 2023). Esta infraestructura sostiene una vocación agrícola tan intensiva que el 94% del agua disponible en la entidad se destina al riego, y Sinaloa aporta el 30% del total de alimentos que se cosechan en el país, consolidándose como el llamado "granero de México" (Mancera González, 2023).

Esta escala de producción depende, a su vez, de un uso intensivo de agroquímicos. El trabajo etnográfico de Mancera González (2023) documentó el uso discrecional de fertilizantes, mejoradores de tierra, herbicidas, fungicidas e insecticidas en comunidades agrícolas del Valle de Culiacán, señalando que los productores los aplican de forma prácticamente rutinaria, sin asesoría técnica que indique si el cultivo realmente los requiere. Esta dinámica no es exclusiva de un pequeño grupo: se estima que en México la exposición a agroquímicos intoxica mortalmente a 355,000 personas al año (Tamayo et al., 2014, citado en Mancera González, 2023).

La magnitud de esta contaminación química se confirma con evidencia directa: un estudio en un campo agrícola de Navolato, dentro del Distrito de Riego 010, encontró más de 17 plaguicidas distintos en el suelo y el agua, catorce de los cuales aparecieron también en la sangre de los jornaleros agrícolas de la zona (Galindo-Reyes & Alegria, 2018, citado en Mancera González, 2023). Este hallazgo es relevante para el presente proyecto porque confirma que los escurrimientos agrícolas hacia los drenes y ríos de la región no son un riesgo hipotético, sino una carga química medible que, junto con los fertilizantes nitrogenados y fosfatados descritos en la introducción, alimenta el proceso de eutrofización que se documenta con mayor detalle en la sección siguiente.

2.2 Antecedentes de eutrofización documentados en cuerpos de agua en la región.

Sobrecarga de nutrientes agrícolas e hipereutrofización: Las evaluaciones en ríos y drenes agrícolas (como en los valles del Culiacán, Fuerte, Sinaloa y Presidio) evidencian que el exceso de fertilizantes representa la mayor fuente de contaminación. En el centro-norte, los niveles de fósforo total sitúan a la red hídrica en condiciones de eutrofización e hipereutrofización. (Castañeda-Ruelas et al., 2023, p. 363). Por su parte, hacia el sur, el río Presidio supera de forma constante en casi toda su cuenca media y

baja el límite de fósforo recomendado internacionalmente para prevenir florecimientos algales. (Mendivil-García et al., 2023, pp. 278, 282).

I**mpacto masivo de drenes hacia los sistemas costeros:** Los sistemas de drenaje agrícola y efluentes superficiales transportan la mayor parte del nitrógeno y fósforo hacia los esteros y lagunas costeras. En el norte, los drenes aportan entre el 87.9% y el 90.8% del nitrógeno inorgánico disuelto que entra a las bahías de Topolobampo y Navachiste (Escobedo Urías, 2010, pp. xvii, 64-65). A esto se suma la actividad camaronícola, que en zonas como la Laguna Macapule vierte anualmente más de 46 toneladas de nitrógeno y 4.6 toneladas de fósforo, predominando compuestos orgánicos que demandan grandes cantidades de oxígeno para descomponerse (Escobedo Urías et al., 2008, pp. 3, 20).

Zonas críticas y estatus trófico elevado: Las evaluaciones mediante índices de calidad del agua reflejan un deterioro ecológico severo. El índice trófico ha catalogado de forma consistente a las lagunas del norte (Topolobampo y Navachiste) y del sur (Estero de Urías en Mazatlán) dentro de categorías de nivel trófico alto a muy alto (eutróficas) y con calidad de agua pobre (Escobedo Urías, 2010, p. xviii; Izaguirre Flores, 2012, pp. 70-74). El punto más crítico documentado en Mazatlán se ubica en el Estero del Infiernillo, donde la concentración de clorofila y amonio han alcanzado picos extremos debido a las descargas urbanas (Izaguirre Flores, 2012, pp. 45, 53, 91).

Pérdida de oxígeno y riesgo biológico: En más del 80% de los puntos monitoreados en la entidad se presentan problemas de déficit severo de oxígeno disuelto (hipoxia), producto de la descomposición bacteriana de la abundante materia orgánica. Esta situación se agrava con altas concentraciones de bacterias (Escherichia coli y coliformes fecales) procedentes de drenajes urbanos y comunidades sin alcantarillado, registrándose millones de unidades en las desembocaduras y esteros de Culiacán, Ahome, Navolato y Mazatlán (Castañeda-Ruelas et al., 2023, p. 368; Izaguirre Flores, 2012, p. 67; Mendivil-García et al., 2023, p. 280).

3. Fundamentos de la solución basada en Inteligencia Artificial

3.1 ¿Por qué IA y no solo estadística tradicional?

Los métodos estadísticos clásicos (regresión lineal simple o múltiple) parten del supuesto de que las variables se relacionan de forma lineal entre sí, lo cual rara vez ocurre en sistemas ambientales complejos. La relación entre nutrientes, oxígeno disuelto y demás parámetros fisicoquímicos es de naturaleza no lineal y multivariable: el efecto de un aumento de fósforo sobre el oxígeno disuelto no es constante, sino que depende simultáneamente de la temperatura, el caudal, la turbidez y la temporada del año (Aguilar Aguilar & Obando-Díaz, 2020, p. 48). Los algoritmos de Machine Learning, a diferencia de la estadística tradicional, están diseñados para aprender estas relaciones

complejas directamente de los datos históricos, sin necesidad de que el investigador defina de antemano la forma matemática exacta de la relación entre variables.

3.2 Machine Learning aplicado a monitoreo ambiental: antecedentes

La aplicación de IA para predecir la calidad del agua ya cuenta con antecedentes sólidos, incluyendo casos directamente relacionados con el fenómeno que aborda este proyecto. Un ejemplo destacado es el trabajo de investigadores de la Universidad de Connecticut, quienes entrenaron modelos de Machine Learning con datos de 2002 a 2017 del lago Erie "Uno de los cuerpos de agua dulce más afectados por eutrofización en Norteamérica, producto de escorrentías agrícolas con fertilizantes" para predecir niveles de oxígeno disuelto como indicador clave de hipoxia (Globaqua, 2024).

En un contexto más cercano al de este proyecto, Delgado Pinedo y Trujillo Vasquez (2025, p. xx) aplicaron distintos modelos de Machine Learning (regresión lineal múltiple, SVM, árboles de decisión, Random Forest, redes neuronales artificiales y XGBoost) para analizar la calidad del agua de la cuenca del río Chancay-Lambayeque (Perú), en una región también agrícola. Sus resultados mostraron que Random Forest, árboles de decisión y redes neuronales artificiales lograron buen desempeño prediciendo el oxígeno disuelto (R^2 de 0.741, 0.714 y 0.785 respectivamente) y la demanda bioquímica de oxígeno (R^2 de 0.856, 0.901 y 0.871 respectivamente) (Delgado Pinedo & Trujillo Vasquez, 2025, p. xx). Los autores identificaron además al Cadmio y al Fósforo Total como los parámetros con mayor relevancia para ambas variables, seguidos por el Boro y el Litio en el caso del oxígeno disuelto, y por el Nitrógeno Total y el Cromo Total en el caso de la demanda bioquímica de oxígeno (Delgado Pinedo & Trujillo Vasquez, 2025, p. xxi) un hallazgo consistente con lo que se ha documentado para las cuencas de Sinaloa en la sección 2.2 de este trabajo.

3.3 Algoritmos seleccionados: árboles de decisión y métodos de ensamble

Con base en estos antecedentes, este proyecto adoptará algoritmos de árboles de decisión y sus variantes de ensamble (Random Forest y/o Gradient Boosting), por las siguientes razones:

- **Manejo de relaciones no lineales:** capturan interacciones complejas entre variables fisicoquímicas sin requerir transformaciones previas de los datos (Aguilar Aguilar & Obando-Díaz, 2020, p. 53, donde se documenta que los árboles de regresión estiman la salida a partir de reglas de decisión inferidas directamente de los datos).
- **Interpretabilidad:** a diferencia de las redes neuronales, permiten identificar qué variables (por ejemplo, fósforo total o temperatura) tienen mayor peso en la predicción del riesgo, lo cual es valioso para que autoridades no técnicas comprendan por qué el modelo emite una alerta.

- **Buen desempeño con datasets de tamaño moderado:** a diferencia del Deep Learning, que requiere grandes volúmenes de datos para generalizar bien, los métodos de ensamble funcionan adecuadamente incluso con el tipo de dataset histórico limitado que se espera obtener de fuentes oficiales como CONAGUA para el periodo de un año de este proyecto (Aguilar Aguilar & Obando-Díaz, 2020, p. 57, donde se muestra que la mayoría de los estudios revisados trabajan con bases de datos de un año o más, no necesariamente extensas).
- **Evidencia empírica favorable:** como se mostró en la sección 3.2, estos algoritmos ya han demostrado buen desempeño en estudios comparables de cuencas agrícolas.

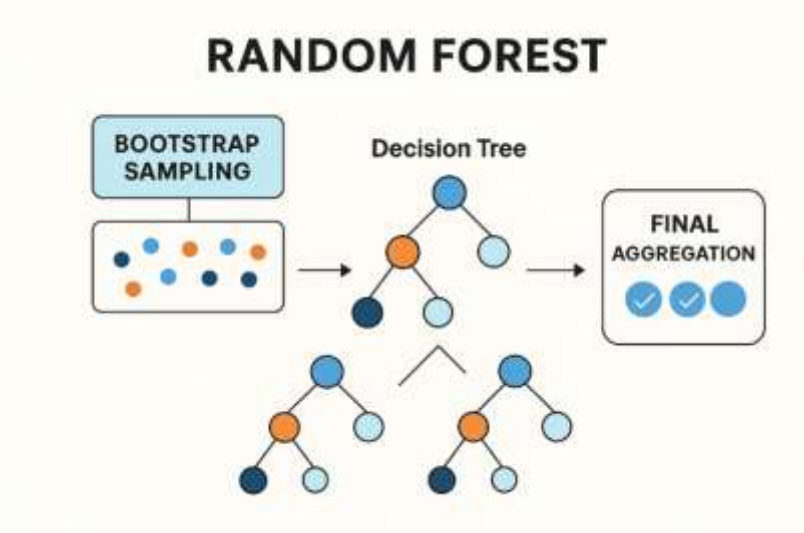


Figura 2. *Arquitectura del algoritmo Random Forest (Bagging). Muestra el entrenamiento en paralelo de múltiples árboles de decisión sobre subconjuntos de datos generados por remuestreo (bootstrap), combinando sus predicciones individuales para obtener un resultado final robusto.*

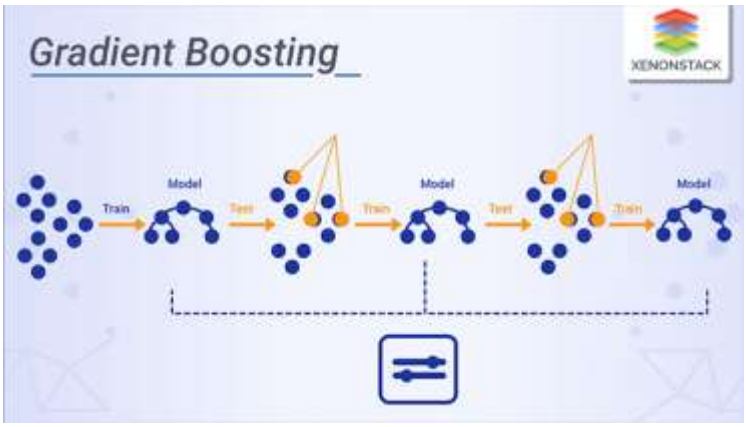


Figura 3. *Funcionamiento secuencial del algoritmo Gradient Boosting.* Ilustra el entrenamiento iterativo donde cada nuevo árbol de decisión se enfoca en corregir los errores o residuos residuales cometidos por el modelo anterior.

4. Metodología

4.1 Fuentes y recolección de datos

La recopilación de información primaria se obtuvo de los registros públicos de la Red Nacional de Medición de la Calidad del Agua (RENAMECA), administrada por la Comisión Nacional del Agua (CONAGUA).

4.1.1 Periodo de estudio

Se analizan series temporales históricas con muestreos periódicos (mensuales/bimestrales) que abarcan ciclos hidrológicos representativos, permitiendo contrastar las fluctuaciones entre la época de sequía y la temporada de lluvias.

4.1.2 Sitios de monitoreo elegidos en Sinaloa

Se seleccionaron estaciones estratégicas ubicadas en los principales cuerpos de agua de la entidad federativa, abarcando desde las zonas altas/medias hasta las zonas de descarga costera y confluencia con drenes agrícolas y efluentes urbanos:

Cuenca del Río Presidio (Sur): Estaciones a lo largo del cauce principal desde la presa Picachos hasta su desembocadura.

Cuenca del Río Culiacán / Humaya / Tamazula (Centro): Sitios con influencia directa de las descargas urbanas de la zona metropolitana de Culiacán y los retornos de riego del Valle de Culiacán.

Cuenca de los Ríos Sinaloa y El Fuerte (Centro-Norte): Puntos de monitoreo localizados en los cauces principales y en la red de drenes colectores de los Distritos de Riego 063 (Guasave) y 075 (Valle del Fuerte).

4.2 Variables del modelo

Para reducir la dimensionalidad de la base de datos original y optimizar el rendimiento del algoritmo Random Forest, se seleccionó un subconjunto de variables con base en su relevancia directa en el proceso de eutrofización:

4.2.1 Parámetros fisicoquímicos básicos:

Temperatura del agua (T, °C): Modula la tasa metabólica del fitoplancton y la solubilidad física de los gases disueltos.

Potencial de hidrógeno (pH): Indicador del equilibrio del carbono inorgánico; ascensos marcados se asocian a intensa fotosíntesis algal.

Conductividad Eléctrica (CE) / Sólidos Disueltos Totales (SDT): Estimadores de la salinidad y arrastre de sales y fertilizantes disueltos.

4.2.2 Nutrientes y materia orgánica:

Nitratos (NO3), Nitritos (NO2) y Nitrógeno Amoniacal (NH4): Compuestos nitrogenados limitantes o co-limitantes que favorecen la proliferación de biomasa vegetal.

Fósforo Total (P): Nutriente co-limitante identificado de forma consistente en la literatura revisada como uno de los principales determinantes de la eutrofización en cuencas agrícolas, tanto en Sinaloa (Castañeda-Ruelas et al., 2023) como en estudios comparables de cuencas agrícolas (Delgado Pinedo & Trujillo Vasquez, 2025).

4.2.3 Variables objetivo :

Oxígeno Disuelto (OD o % saturación): Variable fundamental de respuesta ecológica que refleja el balance entre fotosíntesis y respiración/degradación bacteriana. Es la variable principal que el modelo busca predecir, ya que sus niveles críticos definen directamente el riesgo de hipoxia.

Demanda Bioquímica de Oxígeno (DBO5): Indica la cantidad de materia orgánica presente en el agua y, por lo tanto, el oxígeno que se consumirá en su proceso de descomposición. Se predice de forma complementaria al OD, al ser ambos los indicadores sobre los que se construyen las clases de riesgo

4.2.4 Variable contextual:

Ciclo agrícola regional: Atributo categórico binario (0 = receso/preparación; 1 = periodo de riego intensivo y aplicación de fertilizantes, predominantemente durante el ciclo Otoño-Invierno en Sinaloa), que representa la presión de fuentes difusas sobre los cauces.

4.3 Preprocesamiento de datos

El flujo de preparación y depuración de la información se estructura en las siguientes etapas:

Limpieza y valores de censura: Se eliminan registros duplicados y se tratan las cadenas de texto asociadas a límites de detección analítica (como valores reportados como < LD o No Detectable), reemplazándolos por la mitad del límite de detección cuantificable (LD/2) para evitar sesgos a cero.

Tratamiento de valores faltantes (Missing Data): Debido a fallas de sensores o periodicidades irregulares de muestreo, los datos faltantes se gestionan mediante

imputación por interpolación temporal lineal (para series temporales continuas del mismo punto) o mediante el algoritmo de vecinos más cercanos (KNN Imputer) considerando estaciones contiguas con perfiles hidrológicos similares.

4.4 Definición de las clases de riesgo

Para que el modelo de IA aprenda a clasificar el estado ecológico, se define una variable objetivo (target) categórica con tres niveles de riesgo, basada en los criterios normativos de CONAGUA (Sistema de Semáforo de Calidad del Agua) y en los umbrales biológicos críticos de Oxígeno Disuelto (OD) y Demanda de Oxígeno (DBO5):

Clase 1: Riesgo Bajo (Verde / Aceptable):

Criterio de OD: >= 5.0mg * L-1

Criterio de DBO5: <= 6.0mg*L-1

Condición ecológica: El cuerpo de agua conserva niveles suficientes de oxígeno para mantener la vida acuática nativa y la descomposición natural sin presentar síntomas de asfixia o hipoxia.

Clase 2: Riesgo Moderado (Amarillo / Alerta temprana):

Criterio de OD: Entre 3.0 y 4.99 mg *L-1

Criterio de DBO5: Entre 6.1 y 30.0 mg*L-1

Condición ecológica: El cuerpo de agua experimenta un estrés respiratorio moderado. Coincide con incrementos de nitrógeno y fósforo que comienzan a consumir el oxígeno disponible. Es la ventana ideal para emitir alertas preventivas antes del florecimiento algal masivo.

Clase 3: Riesgo Crítico (Rojo / Hipoxia severa):

Criterio de OD: < 3.0 mg*L-1 (o condiciones de anoxia < 1.0mg *L-1)

Criterio de DBO5: > 30.0mg*L-1

Condición ecológica: Colapso del ecosistema ("zona muerta"), mortandad masiva de peces y fauna bentónica por asfixia, proliferación de bacterias anaerobias y emanación de gases tóxicos.

4.5 Entrenamiento y validación del modelo

Para garantizar que el modelo predictivo tenga capacidad de generalizar y no sufra de sobreajuste (overfitting), se sigue el siguiente protocolo:

División del conjunto de datos: Se realiza una partición estratificada en un 70% para entrenamiento, 15% para validación (ajuste de hiperparámetros) y 15% para prueba final (test set independiente). En experimentos donde se evalúe la capacidad de pronóstico en el tiempo, se utiliza una división cronológica para evaluar cómo predice el modelo ciclos futuros a partir del pasado histórico.

Métricas de evaluación del desempeño: Debido al desbalance de clases y a la importancia de no ignorar eventos de riesgo agudo, no se emplea la exactitud global como métrica única. Se utilizan:

Precisión: Para medir cuántas de las alertas emitidas fueron efectivamente situaciones de riesgo real (evitar falsas alarmas).

Sensibilidad: Métrica primordial para minimizar los falsos negativos; asegura que el modelo no pase por alto episodios de riesgo crítico que terminen en mortandad de fauna.

Matriz de confusión: Para visualizar puntualmente los cruces entre las condiciones reales observadas y las clasificaciones del modelo.

Agenda

Actividad	Mes 1				Mes 2				Mes 3				Mes 4				Mes 5				Mes 6				Mes 7			
Fase 1 — Compilación de la base de datos histórica																												
Descarga de registros de CONAGUA-RENAMECA																												
Solicitud de datos complementarios a CONAGUA (Distritos de Riego) e INIFAP																												
Consolidación de los datos en una base estructurada (CSV)																												
Fase 2 — Preprocesamiento y normalización de los datos																												
Limpieza de valores atípicos y registros faltantes																												
Etiquetado de observaciones según ciclo agrícola																												
Definición de umbrales de riesgo (bajo, moderado, critico)																												
Carga del dataset final																												
Fase 3 — Entrenamiento y optimización de los modelos																												
Implementación de modelos (RF, árboles de decisión)																												
Ajuste de hiperparámetros y pruebas iterativas																												
Comparación de resultados																												
Selección del modelo final																												

Fase 4 — Validación del sistema																												
Evaluación con métricas de clasificación (precisión, sensibilidad, matriz de confusión)																												
Análisis de importancia de variables (fósforo, nitrógeno)																												
Documentación de resultados																												
Fase 5 — Diseño del prototipo y cierre																												
Desarrollo del panel de visualización																												
Redacción del documento de investigación																												
Preparación de la presentación																												
Ensayo de la presentación																												
Entrega del proyecto																												

Tabla 1. *Cronograma de actividades proyectado a 7 meses para el desarrollo del sistema predictivo.*

Conclusiones

La eutrofización y la falta de oxígeno en los ríos y drenes agrícolas de Sinaloa no es algo que "podría pasar", es un problema que ya está pasando y que se puede medir: los datos revisados muestran que en más del 80% de los puntos que se monitorean en el estado hay muy poco oxígeno en el agua, y que lugares como las bahías de Topolobampo, Navachiste y el Estero de Urías ya están muy contaminados. Esto pasa porque Sinaloa produce el 30% de los alimentos del país, y esa agricultura tan intensa es justamente lo que está causando el problema.

Ante esto, este proyecto propone una alternativa a la forma en que hoy se revisa el agua, que es lenta: alguien va, toma una muestra, la manda al laboratorio y los resultados tardan días o semanas en llegar. Al revisar estudios parecidos, como uno hecho en el río Chancay-Lambayeque en Perú, encontramos que los modelos de IA que planeamos usar (árboles de decisión, Random Forest) ya han funcionado bien para predecir estos problemas, con resultados bastante precisos. Esto nos da confianza en que la idea sí es posible de lograr para el caso de Sinaloa.

El proyecto está diseñado para hacerse en un plazo de siete meses, así que se planteó de forma que sí se pueda cumplir en ese tiempo: nos enfocamos en las cuencas de los ríos Culiacán, Sinaloa, El Fuerte y Presidio, usaremos datos que ya existen (no vamos a instalar sensores propios ni tomar muestras en campo), y en vez de crear un sistema completo listo para usarse, la meta es entregar un prototipo que demuestre que la idea funciona. Esto no le quita valor al proyecto, al contrario, lo hace algo que sí se puede terminar con el tiempo y los recursos que tenemos como estudiantes.

Si el proyecto se llega a concretar, el modelo y el panel de visualización servirían como una herramienta barata que ayudaría a las autoridades y a los agricultores a tomar decisiones antes de que ocurra una mortandad de peces u otro daño grave, sin necesidad de reemplazar el monitoreo que ya existe, sino apoyándolo. Además, esta misma forma de trabajar podría usarse después en otras cuencas del país que tengan problemas parecidos.

Finalmente, es importante decir que este proyecto tiene límites claros: no se van a tomar muestras propias en campo, ni se van a analizar otros contaminantes como metales pesados o bacterias fecales. Esas partes quedarían pendientes para un trabajo futuro, una vez que se compruebe que la idea principal sí funciona.

Citas Bibliográficas

Castañeda-Ruelas, G. M., Arce-Navarro, K. S., & colaboradores. (2023). Calidad y uso potencial de la red hidrográfica del centro-norte de Sinaloa, México. Tecnología y ciencias del agua, 14(2), 337-375. https://doi.org/10.24850/j-tyca-14-02-09

Ramírez-Zierold, J. A., Valdespino-Castillo, P. M., Monroy-Ríos, E., Barjau-Aguilar, M., Gerardo-Nieto, Ó., Merino-Ibarra, M., Castillo Sandoval, S., Vilaclara-Fatjó, G., & Gaytán-Herrera, M. (2023). Eutroficación de cuerpos de agua: causas, consecuencias y soluciones basadas en la naturaleza. Impluvium, (23), 23–30.

Zamora, S. I. (2010). Algunos principios en el rescate de ríos urbanos. En R. González, M. L. Hernández, C. M. Perló, & S. I. Zamora, *Rescate de ríos urbanos: Propuestas conceptuales y metodológicas para la restauración y rehabilitación de ríos*. PUEC, Universidad Nacional Autónoma de México.

Mateos-Aparici Baixauli, R. (2020). Tratamiento ecológico para la eutrofización y la anoxia en las balsas de riego. En XXXVIII Congreso Nacional de Riegos (AERYD) (pp. 1–5). Cartagena, España. https://doi.org/10.31428/10317/8715

Mancera González, O. (2023). Las codependencias de la agroindustria en Sinaloa, México. Perfiles Latinoamericanos, 31(61). https://doi.org/10.18504/pl3161-006-2023

Mendivil-García, K., et al. (2023). Preservación del agua en Sinaloa, México, a través del monitoreo y evaluación de la calidad del agua: Estudio de Caso: Río Presidio. Ambiens Techné et Scientia México, 11(2), 117-135.

Escobedo-Urías, D. C. (2010). Diagnóstico y descripción del proceso de eutrofización en lagunas costeras del norte de Sinaloa (Tesis doctoral). Centro Interdisciplinario de Investigaciones y Estudios sobre Medio Ambiente y Desarrollo (CIIEMAD), Instituto Politécnico Nacional, México.

Escobedo-Urías, D. C., et al. (2008). Flujo e impacto de nutrientes y materia orgánica derivados de la acuicultura en sistemas estuarinos de Sinaloa. CIIDIR-IPN Unidad Sinaloa.

Izaguirre Flores, E. I. (2012). Variación anual de la calidad del agua del sistema estuarino de Urías, Sinaloa, México (Tesis de maestría). Centro de Investigación en Alimentación y Desarrollo, A.C. (CIAD), Mazatlán, Sinaloa.

Aguilar Aguilar, A. C., & Obando-Díaz, F. F. (2020). Aprendizaje automático para la predicción de calidad de agua potable. Ingeniare, Universidad Libre-Barranquilla, 16(28), 47-62. https://doi.org/10.18041/1909-2458/ingeniare.28.6215

Globaqua News & Globaqua News. (2024, June 3). Machine Learning para modelar lagos y poder predecir la calidad del agua. Globaqua. https://www.globaqua.com/noticia/el-

uso-del-aprendizaje-automatico-para-modelar-lagos-y-poder-predecir-la-calidad-del-agua/

Delgado Pinedo, D. F., & Trujillo Vasquez, S. A. (2025). Modelos de machine learning para el análisis de calidad del agua y su contribución para la agricultura [Tesis de licenciatura, Universidad de Lima]. https://hdl.handle.net/20.500.12724/23146